

Sobel filter na CUDA – Ubrzanje obrade slike pomoću paralelizma

Ivan Akrapović, Jozo Krstanović, Dominik Mišadin

Split, lipanj 2025.

Uvod


- Detekcija rubova ključna u obradi slike
- CPU tradicionalno korišten, ali ograničen za real-time primjene
- GPU omogućuje paralelnu obradu milijuna piksela



Slika 3.2. Originalna slika (lijevo) i detektirani rubovi (desno)

Što je CUDA?

- Razvojna platforma za paralelno programiranje na GPU-u
- Omogućuje pisanje C/C++ koda koji se izvršava na GPU-u
- Ključni pojmovi: `__global__`, `threadIdx`, `blockIdx`, `gridDim`, `blockDim`
- Pogodna za obradu slike zbog neovisne obrade svakog piksela



Sobel filter

- Algoritam za detekciju rubova
- Koristi horizontalni (G_x) i vertikalni (G_y) 3x3 kernel
- Računa gradijent intenziteta → označava "jačinu ruba"
- Formula: $magnitude = \sqrt{g_x^2 + g_y^2}$

X – Direction Kernel

-1	0	1
-2	0	2
-1	0	1

Y – Direction Kernel


-1	-2	-1
0	0	0
1	2	1

100	100	200	200
100	100	200	200
100	100	200	200
100	100	200	200

-1	0	1
-2	0	2
-1	0	1

-100
-200
-100
200
400
<u>+200</u>
=400

Kernel Convolution: The bigger the value at the end, the more noticeable the edge will be.



Slika 3.2. Usporedba prolaza X-osi (lijevo) i Y-osi (sredina) te prolaz sa spojenom magnitudom (desno)

CPU implementacija

- Implementirano u C++ pomoću OpenCV
- Petlje kroz piksele, ručni izračun G_x , G_y i magnitude
- Vrijeme izvođenja:
 - 32 ms (C++),
 - 138 ms (Python)

```
void sobelFilterCPU(const cv::Mat& gray, cv::Mat& output) {  
    int width = gray.cols;  
    int height = gray.rows;  
  
    output = cv::Mat::zeros(height, width, CV_8U);  
  
    for (int y = 1; y < height - 1; ++y) {  
        for (int x = 1; x < width - 1; ++x) {  
            int gx = - gray.at<uchar>(y - 1, x - 1)  
                - 2 * gray.at<uchar>(y, x - 1)  
                - gray.at<uchar>(y + 1, x - 1)  
                + gray.at<uchar>(y - 1, x + 1)  
                + 2 * gray.at<uchar>(y, x + 1)  
                + gray.at<uchar>(y + 1, x + 1);  
  
            int gy = - gray.at<uchar>(y - 1, x - 1)  
                - 2 * gray.at<uchar>(y - 1, x)  
                - gray.at<uchar>(y - 1, x + 1)  
                + gray.at<uchar>(y + 1, x - 1)  
                + 2 * gray.at<uchar>(y + 1, x)  
                + gray.at<uchar>(y + 1, x + 1);  
  
            int magnitude = sqrtf(((float)(gx * gx + gy * gy)));  
  
            output.at<uchar>(y, x) = magnitude > 255 ? 255 : magnitude;  
        }  
    }  
}
```

GPU implementacija

- Paralelno računanje nad svakim pikselom
- Dvije faze: pretvorba u sivu i Sobel filter
- Korištenje grid i block konfiguracije
- Vrijeme izvođenja:
 - 0.555 ms (C++),
 - 1 ms (Python)

```
__global__ void sobelFilter(const unsigned char* gray,
                           unsigned char* output, int width, int height)
{
    int x = blockIdx.x * blockDim.x + threadIdx.x;
    int y = blockIdx.y * blockDim.y + threadIdx.y;

    if (x <= 0 || x >= width - 1 || y <= 0 || y >= height - 1) return;

    int idx = y * width + x;



    int gx = - gray[(y - 1) * width + (x - 1)]
              - 2 * gray[y * width + (x - 1)]
              - gray[(y + 1) * width + (x - 1)]
              + gray[(y - 1) * width + (x + 1)]
              + 2 * gray[y * width + (x + 1)]
              + gray[(y + 1) * width + (x + 1)];

    int gy = - gray[(y - 1) * width + (x - 1)]
              - 2 * gray[(y - 1) * width + x]
              - gray[(y - 1) * width + (x + 1)]
              + gray[(y + 1) * width + (x - 1)]
              + 2 * gray[(y + 1) * width + x]
              + gray[(y + 1) * width + (x + 1)];

    int magnitude = sqrtf((float)(gx * gx + gy * gy));

    output[idx] = magnitude > 255 ? 255 : magnitude;
}
```


Usporedba rezultata



Zaključak

- GPU implementacija Sobel filtra pokazala je ubrzanje od 80 do 130 puta u odnosu na CPU.
- Vrijeme obrade slike (3000×2000 px):
 - CPU: 32 ms (C++), 138 ms (Python)
 - GPU: 0.555 ms (C++), 1 ms (Python)
- Vizualna kvaliteta rezultata između CPU i GPU verzija je gotovo identična.
- CUDA omogućuje efikasnu i brzu obradu slike u stvarnom vremenu.
- Idealno rješenje za primjene s visokim zahtjevima za brzinom:
 - video analitika, autonomna vožnja, industrijski sustavi nadzora
- Analiza potvrđuje veliki praktični doprinos paralelizacije u računalnom vidu.